

# Dokumentacja Projektu 4 (SIGK)

## Autorzy:

- Peng-Yin Chen
  - Paweł Niewierowski
- 

## 1. Cel projektu

Celem projektu jest zaprojektowanie i wytrenowanie neuronowych pól wektorowych, które przeprowadzą płynną transformację przestrzenną (morphing 3D) siatek wybranych obiektów (bunny, dragon, armadillo) w zdefiniowany kształt docelowy czajnika (teapot). Uczenie modelu wykorzystuje augmentację danych, aby przekształcenie było w pełni niezależne od początkowej rotacji i skali obiektów wejściowych. Otrzymane deformacje są poddawane wizualizacji w celu zaprezentowania kroków pośrednich płynnych przejść między kształtami. Następnie badana jest zdolność generalizacji wyuczonych modeli poprzez próbę przetransformowania niewidzianego podczas treningu obiektu (Asian Dragon). Dokładność morfingu i dopasowanie do trójwymiarowego obiektu docelowego oceniane są za pomocą metryk: odległości Chamfera (Chamfer Distance), IoU oraz współczynnika Dice'a. Projekt realizowany jest w języku Python z wykorzystaniem frameworka PyTorch.

## 2. Metodologia i zbiór danych

### 2.1. Przetwarzanie danych

- Zbiór danych opiera się na popularnych modelach siatek 3D z repozytorium Uniwersytetu Stanforda, zapisanych w formacie .obj (królik, smok, pancernik) oraz siatki docelowej przedstawiającej czajnik (często używany w grafice Utah teapot). Dodatkowo, w procesie ewaluacji zdolności generalizacyjnych testowany jest obiekt niewidziany w trakcie treningu (Asian Dragon).
- Zamiast bezpośredniego korzystania ze wierzchołków siatki, dane wejściowe dla sieci są generowane w locie (ang. on-the-fly). Z powierzchni obu siatek stochastycznie próbkowane są chmury punktów (np. 1024 punktów w treningu) z użyciem współrzędnych barycentrycznych, przy czym prawdopodobieństwo wylosowania trójkąta jest proporcjonalne do jego pola powierzchni. Gwarantuje to równomierne pokrycie detali obiektu niezależnie od gęstości siatki bazowej. Obiekty są wstępnie centrowane, a następnie normalizowane tak, aby ich maksymalny promień wynosił 1.0. Kluczowym elementem fazy przetwarzania jest wprowadzona augmentacja: wylosowane punkty źródłowe poddawane są dynamicznym, losowym rotacjom 3D (przy użyciu kwaternionów) wokół wszystkich osi oraz losowemu skalowaniu (w przedziale 0.6–1.4). Wymusza to na modelowanym polu wektorowym zbieżność do docelowego czajnika całkowicie niezależnie od początkowej skali czy orientacji przestrzennej wejścia.

### 2.2. Metryki oceny

Jakość odkształcenia (morfingu) chmury punktów badana była w środowisku trójwymiarowym przy użyciu trzech metryk:

- Odległość Chamfera (Chamfer Distance): Główna metryka geometryczna oceniająca dopasowanie punktów. Oblicza ona średnią kwadratów odległości każdego punktu wynikowego od najbliższego punktu docelowego (oraz w drugą stronę). Niska wartość świadczy o precyzyjnym nałożeniu się na siebie powierzchni obu obiektów i prawidłowym przebiegu transformacji przez pole wektorowe.
- IoU (Intersection over Union – Voxelowe): Miara oceniająca przecięcie dwóch objętości przestrzennych. Wynikowe oraz docelowe chmury punktów podlegają wokselizacji do siatki 3D (o rozdzielczości 64x64x64). Wypukła ona główne wyzwanie architektoniczne – siatki źródłowe nie posiadają "dziur" (genus 0), podczas gdy czajnik ma uchwyt (genus 1), co sprawia, że matematycznie ciągła funkcja deformacji jest silnie karana za niemożność rozerwania materiału, prowadząc do umiarkowanych wyników tej metryki.
- Współczynnik Dice'a (Dice Coefficient): Metryka powiązana z IoU mierząca wolumetryczne pokrycie. Przyznaje większą wagę częściom wspólnym obu poddanych wokselizacji przestrzeni kształtów, co pozwala na dodatkową perspektywę ewaluacji wypełnienia bryła docelowego wolumenu czajnika. Posiada podobne co IoU naturalne ograniczenia przy błędach topologicznych.

### 3. Architektura modelu i proces treningu

W projekcie zastosowano architekturę opartą na ciągłych polach wektorowych (inspirowaną modelami typu Neural ODE / Continuous Normalizing Flows). Sieć bazowa (VectorFieldNet) składa się z dwóch głównych modułów. Pierwszym z nich jest koder oparty na architekturze PointNet (PointNetEncoder), który za pomocą sieci perceptronów (MLP) i operacji max-pooling ekstrahuje globalny wektor cech (reprezentację) dla źródłowej chmury punktów.

Drugim, kluczowym modulem jest sieć estymująca pole prędkości. Przyjmuje ona na wejściu aktualne współrzędne przestrzenne punktu (3D), globalny wektor cech obiektu źródłowego wyciągnięty przez koder oraz zanurzenie aktualnego kroku czasowego (ang. time embedding, zaimplementowane za pomocą fal sinusoidalnych i cosinusoidalnych o różnych częstotliwościach). Sieć ta przewiduje wektor prędkości, wyznaczający kierunek przemieszczenia danego punktu w czasie  $t$ . Co istotne, wagi ostatniej warstwy sieci prędkości inicjalizowane są zerami, dzięki czemu na początku treningu pole wektorowe jest przekształceniem identycznościowym. Ruch punktów obliczany jest iteracyjnie za pomocą całkowania metodą Eulera, przesuając kształt w zdefiniowanej liczbie kroków od stanu początkowego ( $t=0$ ) do końcowego ( $t=1$ ).

Trening przeprowadzany jest niezależnie dla każdej z trzech geometrycznych klas wejściowych (bunny, dragon, armadillo). Do optymalizacji wag modelu wykorzystano algorytm Adam wspierany przez harmonogram wskaźnika uczenia StepLR (zmniejszający krok o połowę co 15 epok). Sieć uczona jest wyłącznie przy użyciu funkcji straty opartej na odległości Chamfera (Chamfer Distance):

$$L = L_{CD}(P_{pred}, P_{target})$$


gdzie  $P_{pred}$  to przemieszczone punkty obiektu po pełnej całej czasu ( $t=1$ ), a

$P_{target}$  to punkty wylosowane z docelowej siatki czajnika. Minimalizacja tej straty przestrzennej wymusza na sieci takie formowanie wektorów prędkości, aby całkowicie i płynnie zdeformować chmurę źródłową i dopasować nakładające się punkty do powierzchni obiektu docelowego.


## 4. Wyniki eksperymentów

| Klasa wejściowa             | IoU    | Dice   | Chamfer |
|-----------------------------|--------|--------|---------|
| Bunny to teapot             | 0.2966 | 0.4574 | 0.0011  |
| Dragon to teapot            | 0.2444 | 0.3927 | 0.0014  |
| Armadillo to teapot         | 0.2588 | 0.4111 | 0.0013  |
| Bunny flow asian dragon     | 0.2011 | 0.3347 | 0.0065  |
| Dragon flow asian dragon    | 0.2232 | 0.3648 | 0.0037  |
| Armadillo flow asian dragon | 0.2420 | 0.3895 | 0.0019  |


## 5. Wizualizacja




Bunny to teapot




Armadillo to teapot



Dragon to teapot



Armadillo flow asian dragon



Bunny flow asian dragon



Dragon flow asian dragon

## 6. Analiza wizualna i wnioski

### 6.1. Wyniki metryk

- Odległość Chamfera: Uzyskane wyniki (dla wszystkich wariantów in-distribution rzędu 0.0011–0.0014) wykazują bardzo niską odległość, co świadczy o wysokiej zbieżności przekształconych chmur z punktami z modelu czajnika. Dowodzi to silnej wierności odwzorowania powierzchni docelowej przez wylosowane ze zdeformowanej siatki punkty, pomimo wysokiego początkowego skomplikowania geometrii źródeł (np. smoka).
- IoU (Intersection over Union): Wyniki oscylujące w granicach 0.24-0.29 (ok. 25-30%) mogą początkowo wydawać się niskie z perspektywy standardowej analizy obrazów, jednak w kontekście wolumetrycznej zgodności 3D stanowią one wynik zgodny z przewidywaniami teoretycznymi dla zastosowanej architektury. Mniejsza wartość

wynika bezpośrednio ze ścisłych limitów nałożonych na pole wektorowe opisujących transformację topologiczną (poruszono m.in. kwestie zamkniętej formy wokselicznej we wskaźnikach).

- Współczynnik Dice'a: Otrzymane metryki wolumetryczne od 0.39 do 0.45 wykazują podobne zjawisko co IoU. Pomiędzy pokryciem, docelową gęstością i geometrią (usztynioną dla konkretnej topologii źródła), Dice w sposób komplementarny obrazuje naturalne problemy transformacji brył o różniące się liczbie otworów (genus różny od zera).

W badaniach out-of-distribution polegających na przyłożeniu nauczonych transformacji do niewidzianego modelu Asian Dragona zauważono spodziewany, jednak niewielki spadek dokładności (Chamfer

0.002–0.006, spadek IoU do ok. 22%). Sieć trenowana np. na modelu Armadillo wykazała największą adaptacyjność w starciu z nową dystrybucją kształtów.

## 6.2. Analiza wizualna i generalne wnioski

Renderowane wizualizacje kroków przejść z wykorzystaniem całkowania numerycznego (np. dla  $t=0, 0.25, 0.50, 0.75, 1.0$ ) dowodzą wyjątkowej spójności wygenerowanego pola wektorowego. Modele skutecznie nauczyły się płynnego zwijania/spłaszczania odnóg wyjściowych (takich jak uszy królika czy ogon i głowa smoka) ku wnętrzu centrum bryły, by ostatecznie wyciągnąć nowe części do kształtu dziobka i charakterystycznego rączki czajnika. Deformacje są wizualnie naturalne i pozbawione gwałtownych szarpnięć we wczesnych momentach kroku integracji.

Pomimo relatywnie dobrych wyników w zbieżności powierzchni (Chamfer), umiarkowane wyniki metryk wolumetrycznych (IoU) znajdują uzasadnienie w topologii obiektów. Modele typu Continuous Normalizing Flow nie posiadają właściwości rozcinania przestrzeni – przekształcają siatki w sposób homeomorficzny. Zarówno królik, pancernik jak i smok to obiekty klasy genus-0 (bez otworów), docelowy model (teapot) posiada uchwyt, co oznacza klasę genus-1. Ze względu na matematyczne limitacje, struktura wejściowa nie zostaje przzerwana w obrębie ucha; zamiast tego materiał zostaje agresywnie naprężony i spłaszczony by uformować kształt wizualnie poparty jako dziura (co w ewaluacji wokseli zgłasza niepoprawne nakładanie lub mikroskopijnej grubości prześwity brył). Wynik uznajemy ostatecznie za obiecujący a pole testowanej generalizacji – za wystarczająco rozwinięte z uwagi na silną naturę niezależności transformacji od orientacji startowej.